INSTITUTO FEDERAL
Sul-rio-grandense

Câmpus
Bagé

EDUCAÇÃO PÚBLICA 100% GRATUITA

Sistema para Detecção de Sonolência e Desatenção de Motoristas em Tempo Real por Visão Computacional

Estudante: Mayara Duarte
Orientador: Marcel Corrêa

Sumário

- Introdução
- Objetivos
- Trabalhos Relacionados
- Materiais e Métodos
  - Sensores
  - Processamento Digital de Imagens
  - Visão Computacional
  - Algoritmos para Detecção
- Resultados Parciais
- Cronograma

Introdução

Acidentes relacionados à **fadiga** e **desatenção** estão entre as principais causas de mortes no trânsito.

Código do sinistro

14 - Condutor dormindo;

17 - Condutor usando o celular;

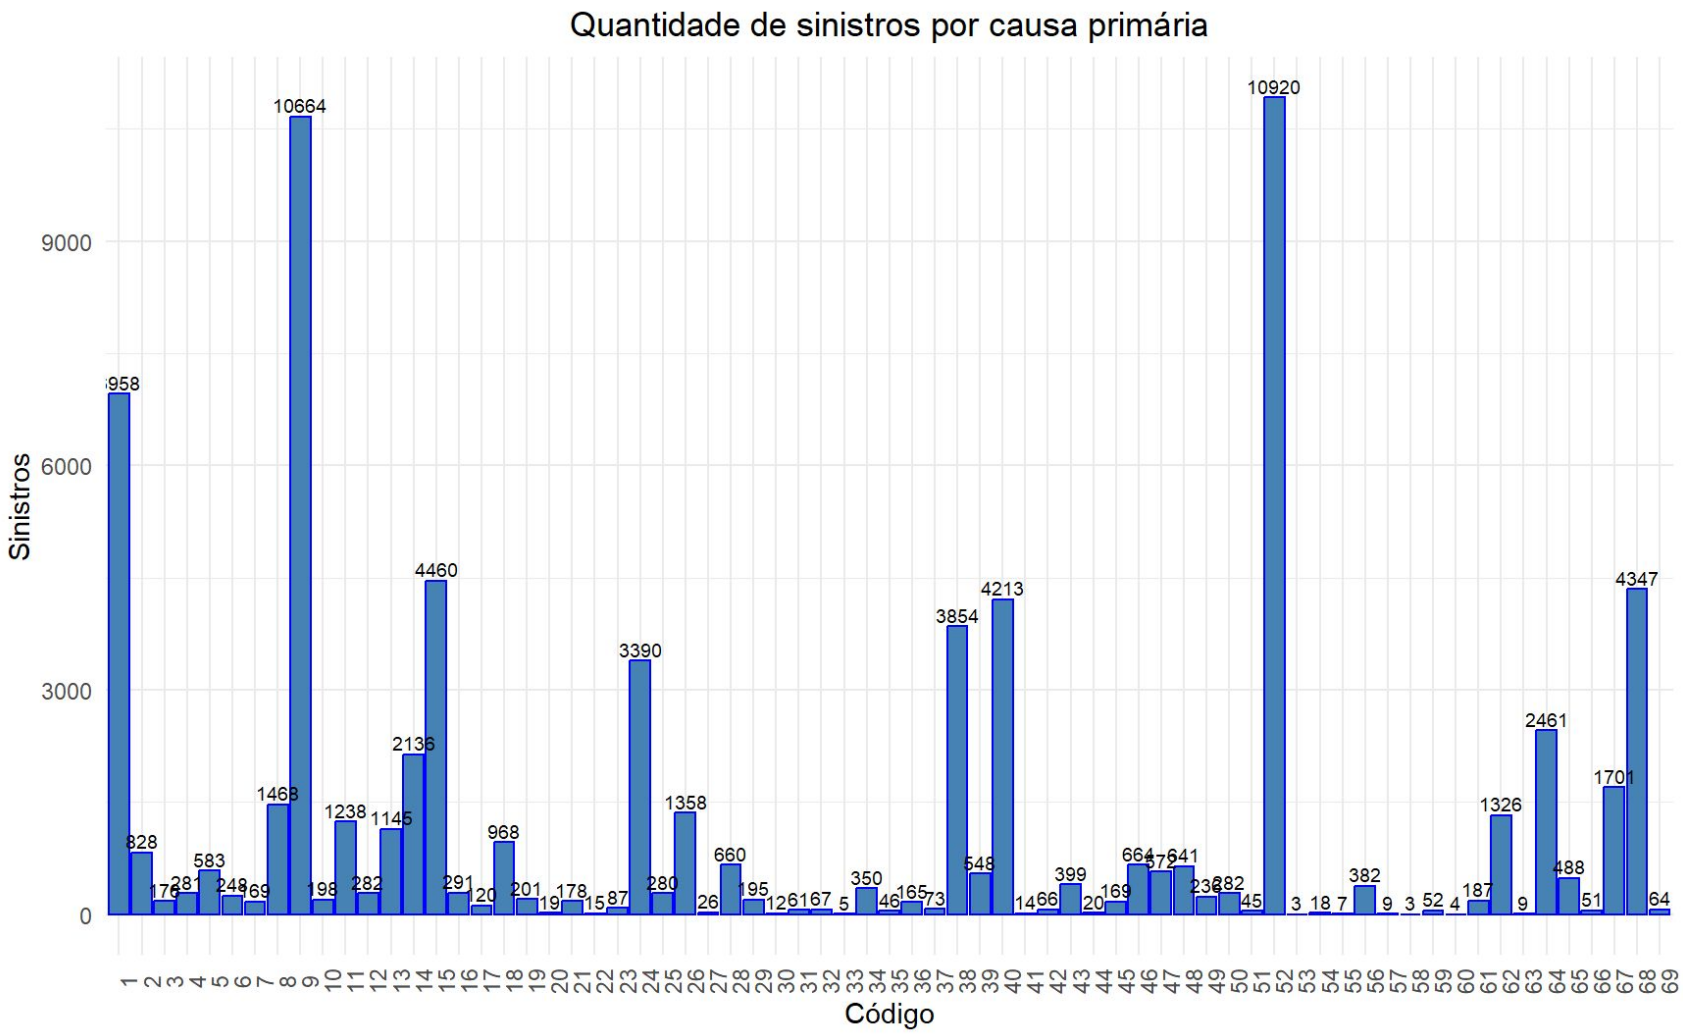

https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/diest-arquivos/anuario-2024_final.html

Introdução

Existem tecnologias embarcadas em automóveis para detectar sonolência, como:

1. Câmeras internas para avaliar o estado do motorista;
2. Câmeras externas e sensores diversos para detectar permanência em faixa;
3. Radares para medir risco de colisão com outros veículos parados;
4. Sensores associados ao volante para detectar movimentos erráticos;

etc…

No entanto, estas funcionalidades ainda estão limitadas ao segmento de carros de mais alto custo.

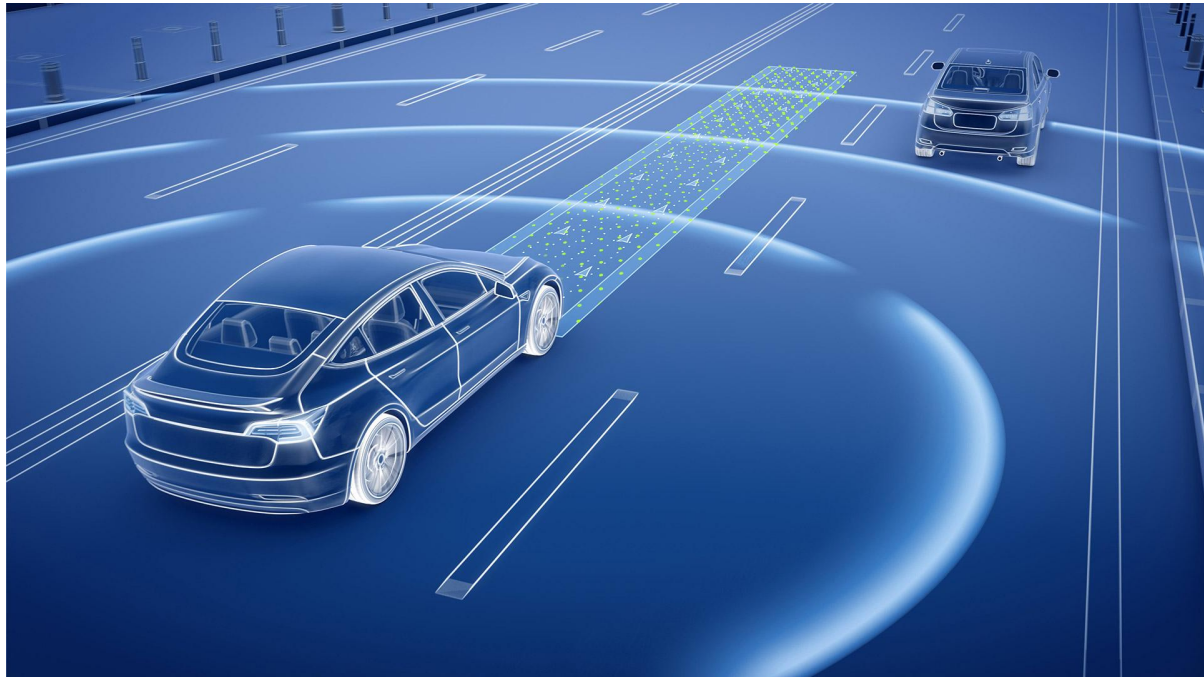

Desafio

Criar um sistema robusto para detecção de fadiga e desatenção que:

- Tenha alta taxa de acerto;
- Faça uso apenas de câmeras voltadas para o motorista;
- Utilize apenas ferramentas abertas para Processamento de Imagem e Visão Computacional.

Objetivos

Geral:

Desenvolver um sistema capaz de detectar **em tempo real** sinais de sonolência e desatenção em motoristas usando **câmera(s)**, **Processamento Digital de Imagens** e **Visão Computacional** possível de ser embarcado em plataformas como Raspberry Pi.

Objetivos

Específicos:

- Capturar posição de elementos da face (olhos, boca, etc…)
- Capturar posição das mãos para tratamento de oclusão
- Implementar pipeline de pré-processamento da imagem de entrada
- Emitir alertas para o motorista
- Emitir alertas ou log para uma central remota usando API Node.js
- Avaliar o desempenho através de experimentos com vídeos reais
- Atingir desempenho compatível com placas como Raspberry Pi 3

Trabalhos Relacionados

Artigo / Autores / Ano	Objetivo	Técnicas utilizadas (EAR, PERCLOS, MAR etc.)	Bocejo com mão na boca?	Tratamento de falha de landmarks / pré-processamento?	Sensores	Limitações identificadas
1. Jie et al. (2018) – "Yawning with your hand over your mouth"	Detectar bocejo e sonolência considerando oclusões faciais	Geometria de boca e olhos; OpenFace landmarks	**Sim** (detecta por perda do ROI)	**Ignoram frames** sem landmarks → dependência total do detector	Câmera RGB	Ignora frames com falha; não generaliza; depende de landmarks perfeitos
2. Agarkar et al. (2023)	Detectar sonolência e bocejos com gestos faciais e mão	Lábios, movimento dos olhos e gestos faciais	**Sim**, mas sem detectar a mão — considera bocejo pela **perda de ROI**	Não robusto; precisou criar dataset próprio; sem pré-processamento avançado	Câmera RGB + Raspberry Pi	Modelos não generalizam; confia em perda de ROI como "mão"; não detecta mão como objeto

Trabalhos Relacionados

Artigo / Autores / Ano	Objetivo	Técnicas utilizadas (EAR, PERCLOS, MAR etc.)	Bocejo com mão na boca?	Tratamento de falha de landmarks / pré-processamento?	Sensores	Limitações identificadas
3. Maheswari et al. (2022)	Sistema integrado usando EAR, MAR, PERCLOS e FAR	EAR, MAR, PERCLOS, novo FAR, CNN	**Não** — trata como perda de ROI	Pré-processamento mínimo; usa câmera normal; CNN decide quando ROI some	Câmera RGB	Confunde qualquer oclusão com mão; não detecta mão; depende de CNN treinado
4. Ramya et al. (2024)	Sistema de detecção de deficiência/sonolência em tempo real	Haar Cascade + EAR + MAR	**Não**	Equalização de histograma + gray scale; assume que isso resolve iluminação	Câmera RGB	Supõe que equalizar é suficiente; assume que landmarks sempre funcionam
5. Zhu et al. (2022) – MDPI	Algoritmo de detecção de fadiga baseado em vídeo	EAR, PERCLOS, MAR; TCDCN	**Não**	Não trata cabeça nem pré-processamento; usa 68 landmarks e só	Câmera RGB	Só monitora olhos/boca; ignora mão na boca; não trata oclusões

Trabalhos Relacionados

Artigo / Autores / Ano	Objetivo	Técnicas utilizadas (EAR, PERCLOS, MAR etc.)	Bocejo com mão na boca?	Tratamento de falha de landmarks / pré-processamento?	Sensores	Limitações identificadas
6. Essahraui et al. (2025) – MDPI	Revisão comparativa de técnicas de análise facial	Avalia técnicas EAR, PERCLOS, CNNs etc.	**Não** (artigo de revisão)	Não se aplica	—	Artigo de revisão; não aborda implementação prática
7. Albadawi et al. (2023)	Detecção de sonolência com machine learning + visual features	EAR, porcentagem de fechamento, frequência de bocejo; pose da cabeça	**Não** (não detecta mão)	Não trata oclusão; limiares variam por pessoa mas **não** implementaram limiar dinâmico	**Câmera IR**	Não detecta mão; não faz pré-processamento; thresholds fixos geram erros individuais
8. Baul et al. (2023)	Sistema com MediaPipe Face Mesh + Python + OpenCV	EAR, MAR, head tilt, limiares dinâmicos	**Não**	Não trata mão cobrindo a boca; sem pré-processamento além do FaceMesh	Câmera RGB	Depende totalmente do FaceMesh; ignora oclusões faciais
9. Florez et al. (2024)	Sistema embarcado com CNN + MediaPipe	EAR, MAR, head pose; CNN	**Não**	Usa MediaPipe mas sem tratamento de oclusões; CNN não cobre mão na boca	Câmera **IR**	Mesmos problemas: não detecta mão, depende de landmarks perfeitos

Trabalhos Relacionados

Com base nos trabalhos estudados, foi identificado que:

- Nenhum deles aplica um pipeline completo de pré-processamento.
- Nenhum trata a direção da visão (desatenção), capturado pela íris do olho.
- O pré-processamento, quando existe, limita-se à equalização de histograma.
- Quando tratam oclusões de bocejos com mão sobre a boca, apenas como “perda do ROI”, sem realmente detectar a mão.
- Alguns estudos utilizam câmeras convencionais, outras câmeras IR, mas nenhum combina ambos os tipos.
- Há dependência excessiva da qualidade bruta da câmera.
- Não há tratamento para situações reais de estrada, como reflexos de faróis, sombras internas ou variações bruscas de iluminação.

Metodologia: Sensores

Inovação: propõe-se uma abordagem híbrida com câmeras RGB + IR

- **Câmera RGB:**
  Ideal em boas condições de iluminação diurna e maiores resoluções.
  Mas em situações de baixa iluminação, produz imagens com baixo contraste e ruidosas.
- **Câmera Infravermelho (IR):**
  Câmeras de infravermelho próximo (700–1000nm) são ideais para cenários noturnos.
  Mas em situações de iluminação solar, o sensor IR captura mais luz do que precisa, gerando imagens saturadas.

A combinação deve garantir funcionamento em qualquer situação.

Metodologia: Pré-Processamento

Modelos de Visão Computacional podem ser drasticamente afetados caso a imagem de entrada não esteja em boas condições.

Inovação: Ao contrário dos trabalhos relacionados, propõe-se a implementação de uma etapa de pré-processamento de imagem usando diversos filtros eficazes para diferentes situações, como por exemplo:

- Equalização de histograma, para melhorar imagens com baixo contraste
- Realce de bordas, para melhor imagens com foco prejudicado
- Redução de ruídos, para recuperar imagens parcialmente corrompidas

etc…

Metodologia: Pré-Processamento

- **Correção Gama**

- Corrige imagens muito escuras ou muito claras.

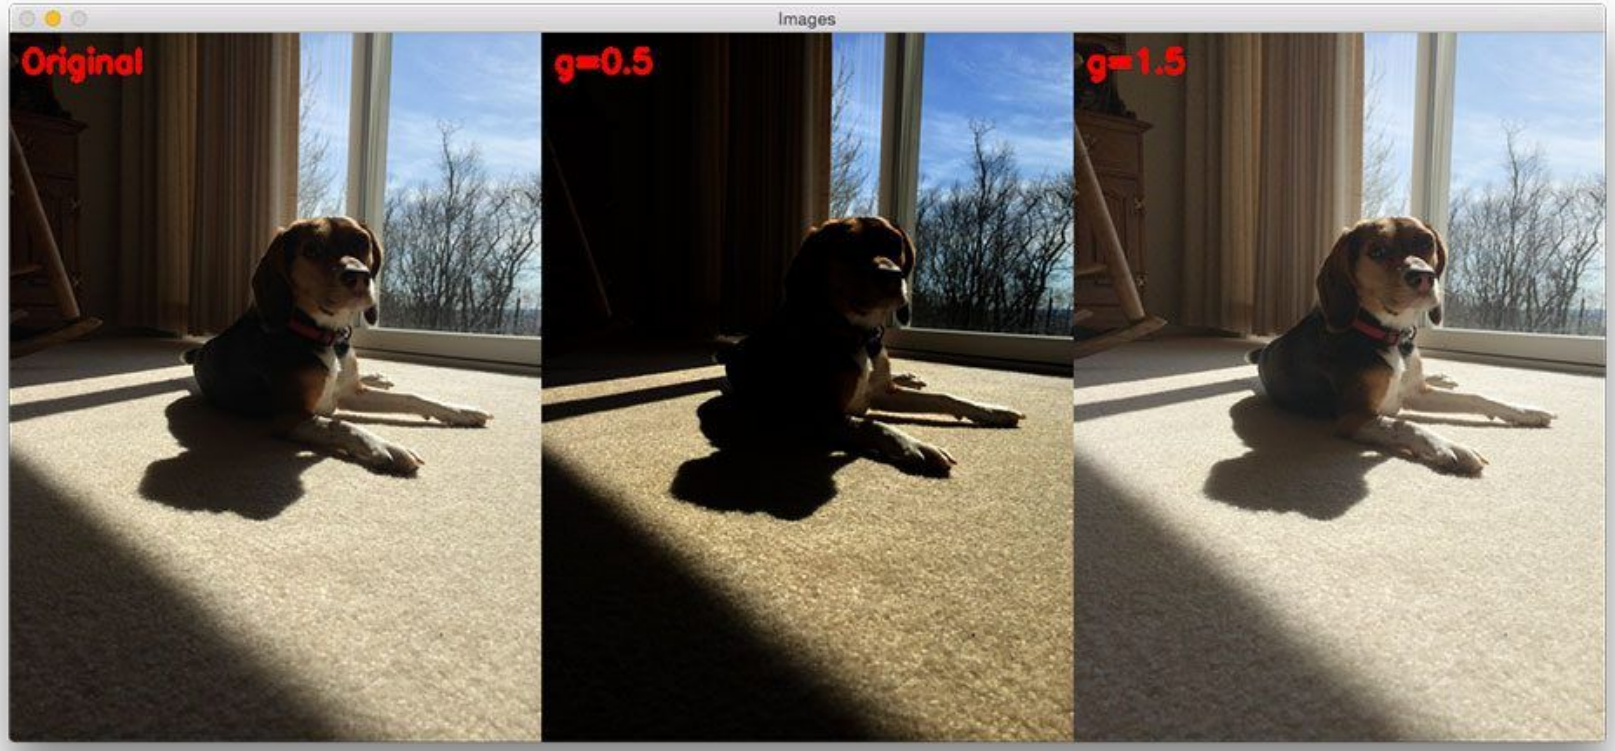

Metodologia: Pré-Processamento

- **Filtro de realce**

- Realça bordas do rosto;
- Corrigir desfoque;
- Melhora detecção de contornos.

Original image

Unsharp Mask filter applied

Metodologia: Pré-Processamento

- **Redução de ruído**

- Remove ruído;
- Mantém detalhes do rosto;

Metodologia: Pré-Processamento

- **Equalização de Histograma**

- Aumenta contraste;
- Faz detalhes do rosto (olhos, boca, contornos) aparecerem melhor.

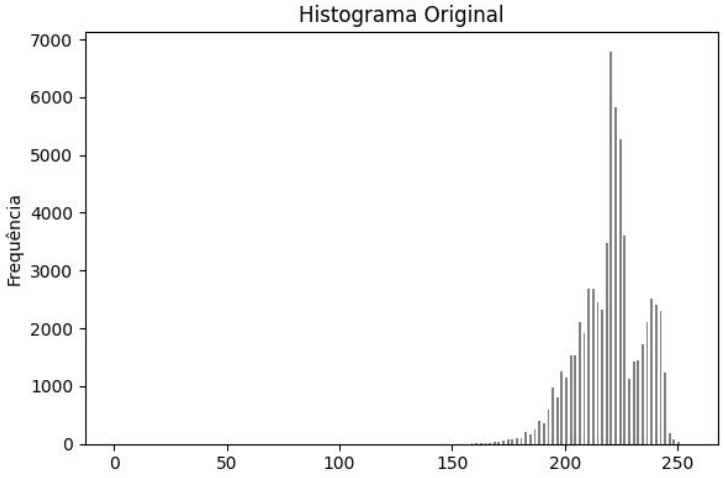

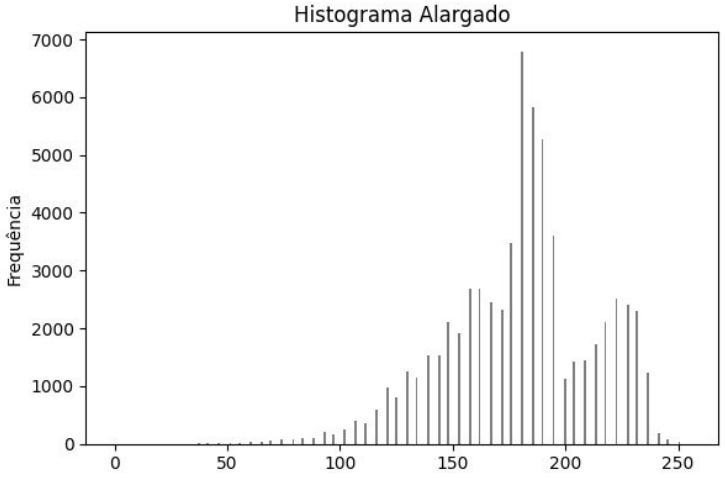

Metodologia: Visão Computacional

MediaPipe - Google

- MediaPipe é um framework de código aberto desenvolvido pelo Google para construir pipelines de percepção;
- É uma aplicação de visão computacional que roda de forma eficiente e em tempo real;
- Foi publicado em 2019;
- É distribuído sob a licença Apache 2.0: Open Source, livre para uso;
- Framework de percepção multimodal, combina modelos de redes neurais pré treinadas;
- O MediaPipe é multiplataforma: funciona em Android, IOS, desktop e Web (JavaScript)

MediaPipe

Metodologia: Visão Computacional

MediaPipe (Google): Face Mesh (468 pontos)

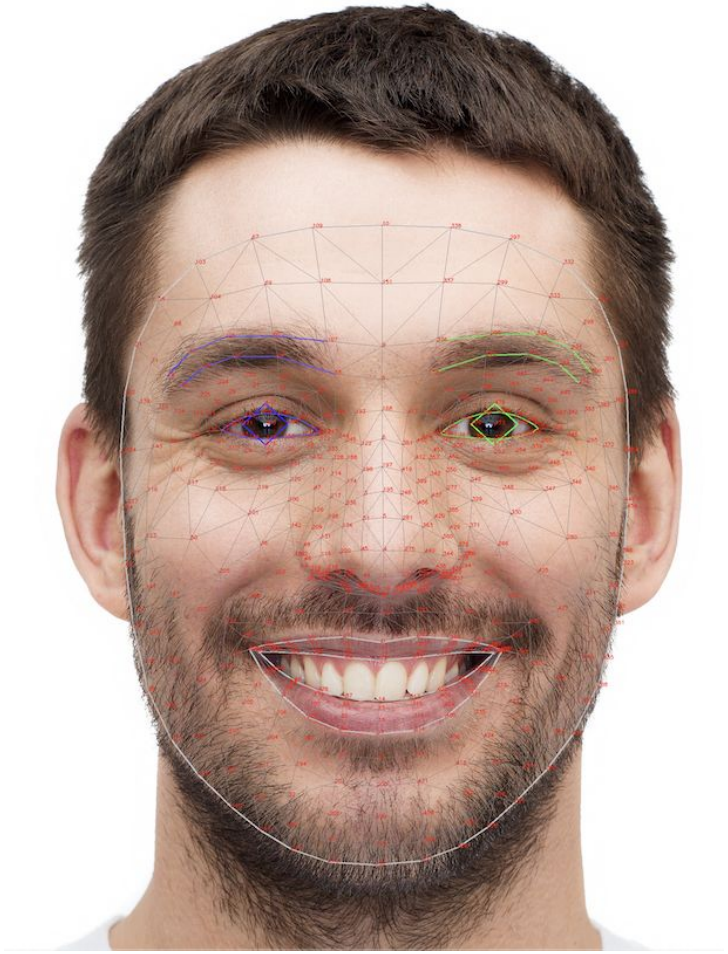

MediaPipe Documentation: Face Mesh, Hands, and Solutions. 2023.

Metodologia: Visão Computacional

MediaPipe (Google): Hands (21 pontos por mão)

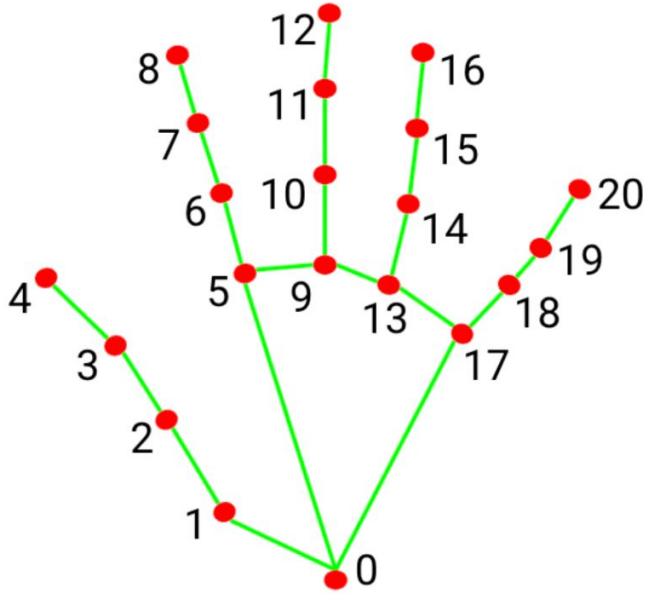

0. WRIST
1. THUMB_CMC
2. THUMB_MCP
3. THUMB_IP
4. THUMB_TIP
5. INDEX_FINGER_MCP
6. INDEX_FINGER_PIP
7. INDEX_FINGER_DIP
8. INDEX_FINGER_TIP
9. MIDDLE_FINGER_MCP
10. MIDDLE_FINGER_PIP
11. MIDDLE_FINGER_DIP
12. MIDDLE_FINGER_TIP
13. RING_FINGER_MCP
14. RING_FINGER_PIP
15. RING_FINGER_DIP
16. RING_FINGER_TIP
17. PINKY_MCP
18. PINKY_PIP
19. PINKY_DIP
20. PINKY_TIP

MediaPipe Documentation: Face Mesh, Hands, and Solutions. 2023.

Metodologia: Visão Computacional

MediaPipe (Google): Irís (5 pontos por irís)

MediaPipe Documentation: Face Mesh, Hands, and Solutions. 2023.

Metodologia: Algoritmos para Detecção

O fluxo completo do sistema proposto é apresentado nas figuras do próximo slide. **Ele consiste em:**

(1) captura de vídeo RGB/IR;

(2) pré-processamento;

(3) detecção de landmarks faciais via MediaPipe Face Mesh;

(4) cálculo das métricas geométricas EAR, MAR e PERCLOS;

(5) detecção de mão sobre a boca/rosto;

(6) classificação do estado do condutor por heurísticas próprias; e

(7) envio dos resultados para API.

Metodologia: Algoritmos para Detecção

A métrica **EAR (Eye Aspect Ratio)** mede **o quanto o olho está aberto ou fechado** usando **6 pontos do olho** do Face Mesh.

Fórmula:

$$\textbf{EAR} = \frac{(P2 - P6) + (P3 - P5)}{2 * (P1 - P4)}$$

P1 e P4: canto externo e interno do olho (distância horizontal)

P2,P3,P5,P6: pontos verticais

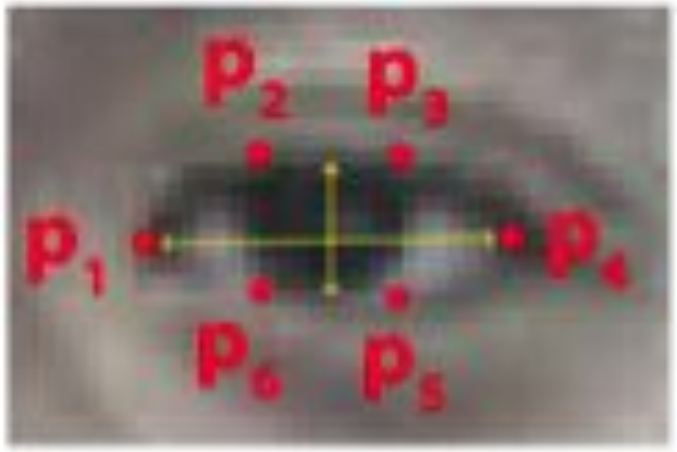

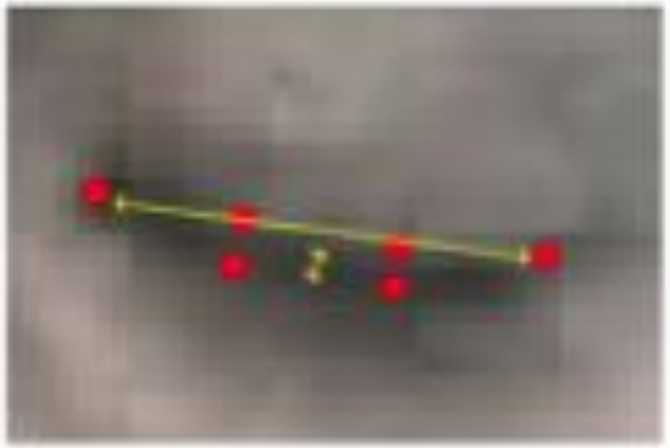

Metodologia: Algoritmos para Detecção

PERCLOS: É a **porcentagem de tempo em que os olhos ficaram fechados** dentro de uma janela de tempo (tipicamente **1 minuto**).

Fórmula

$$\textbf{PERCLOS} = \frac{\text{NÚMERO DE FRAMES COM OLHOS FECHADOS}}{\text{TOTAL DE FRAMES NO INTERVALO}} \times 100$$

Exemplo de interpretação:

PERCLOS < 10% → normal

PERCLOS ≥ 25% → forte sonolência

Metodologia: Algoritmos para Detecção

MAR: métrica que mede **o quão aberta a boca está**, usando 8 ou 6 landmarks da boca.

Fórmula

$$MAR = \frac{(P2 - P8) + (P3 - P7) + (P4 - P6)}{3 * (P1 - P5)}$$

Exemplo de interpretação:

MAR > 0.75 por alguns frames -> bocejo

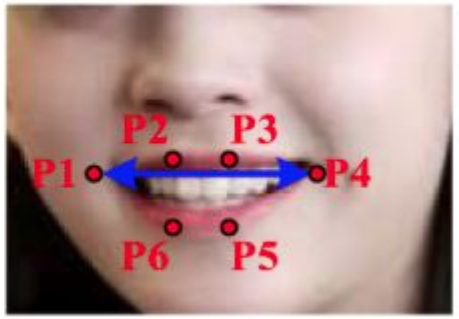

Resultado Parcial

As figuras apresentam um resultado parcial já implementado, referente ao módulo de detecção de bocejo com a mão cobrindo a boca, etapa essencial para lidar com o problema de oclusão facial não tratado pela maior parte dos trabalhos da literatura.

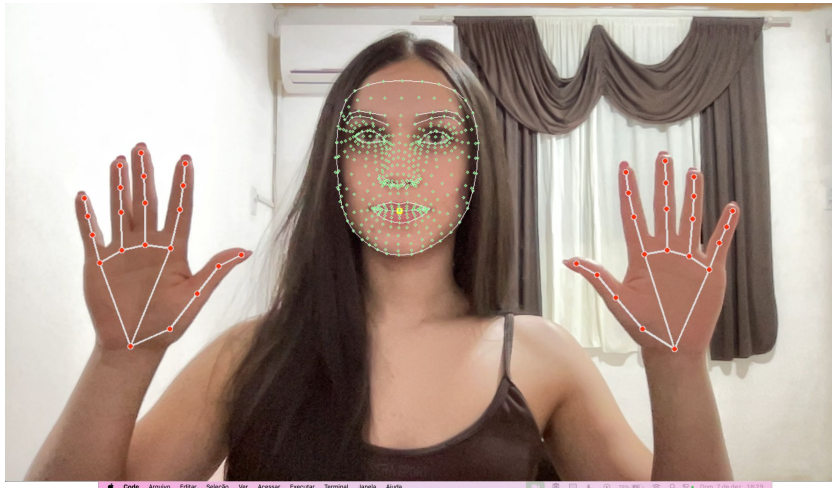

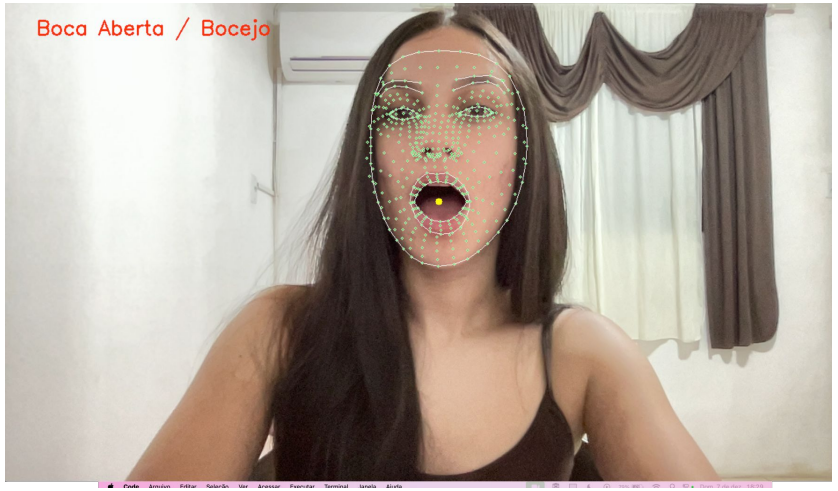

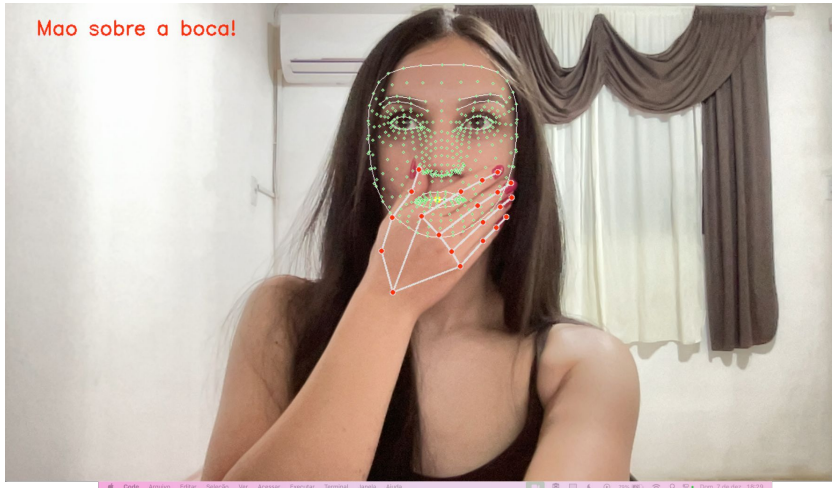

Resultado Parcial

As figuras apresentam um resultado parcial já implementado, referente ao módulo de detecção da íris, etapa essencial para lidar com o problema de desatenção não tratado por nenhum dos trabalhos da literatura.

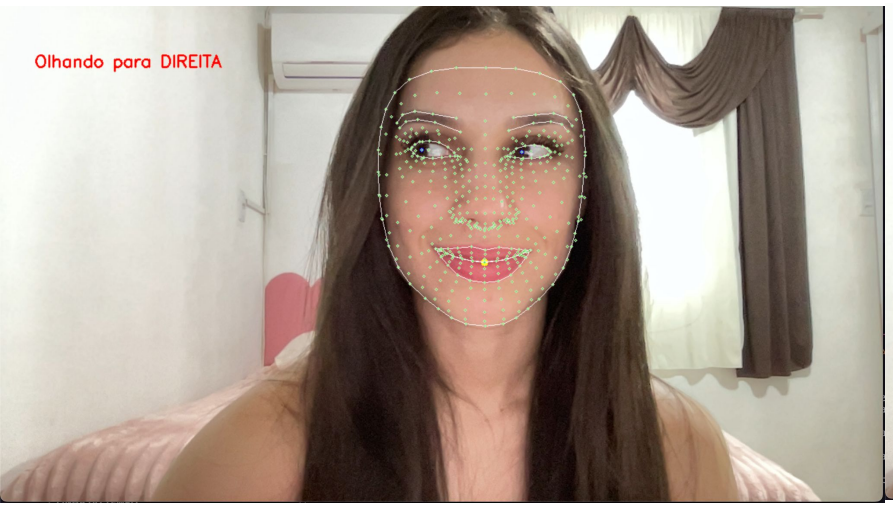

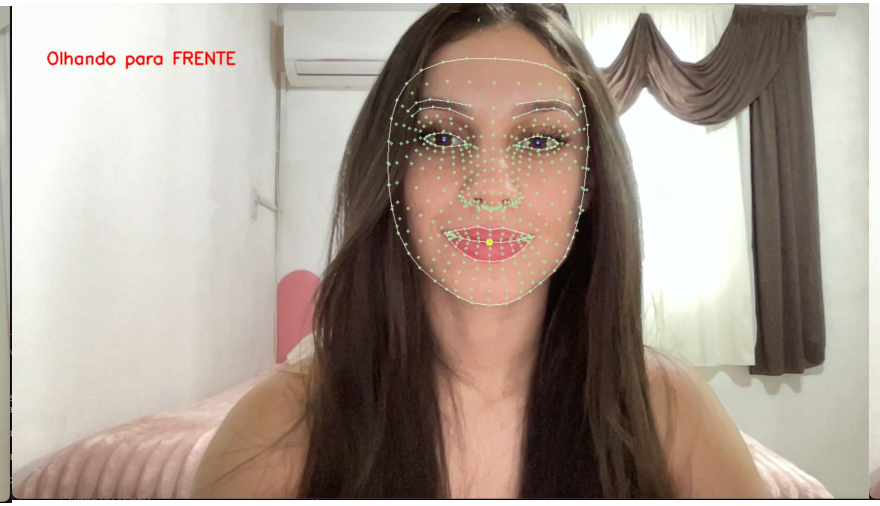

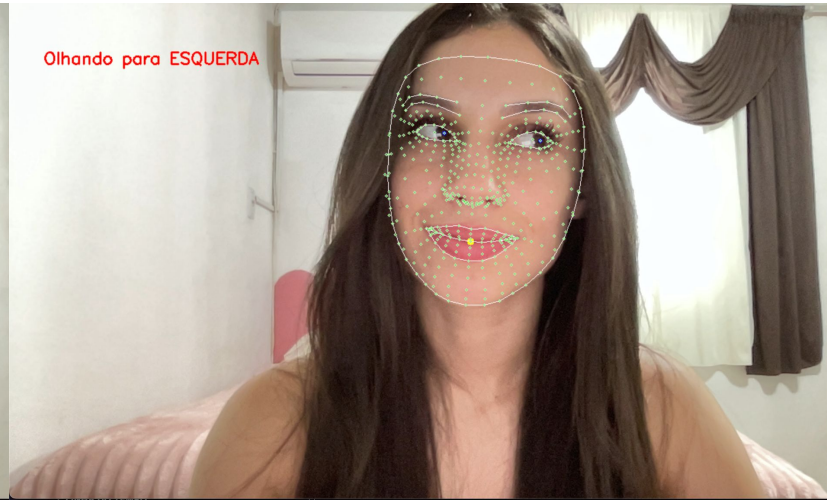

Cronograma

Etapa	Out	Nov	Dez	Jan	Fev	Mar	Abr
Revisão da literatura	X	X					
Detecção Face Mesh + Hands + Íris		X	X				
Implementação do pré-processamento				X			
Integração com Raspberry					X		
API Node.js						X	
Testes e validação						X	X
Escrita final e apresentação							X

Referências

1. Jie et al. (2018) — Yawning With Hand Over Mouth

JIE, Zhuoni; MAHMOUD, Marwa; STAFFORD-FRASER, Quentin; ROBINSON, Peter; DIAS, Eduardo; SKRYPCHUK, Lee.
Analysis of yawning behaviour in spontaneous expressions of drowsy drivers. In: *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)*. IEEE, 2018.
Disponível em: https://ieeexplore.ieee.org/document/8373884. Acesso em: 2025.

2. Agarkar et al. (2023) — Facial Features + Hand Gestures

AGARKAR, Arpit S.; GANDHIRAJ, R.; PANDA, Manoj Kumar.
Driver drowsiness detection and alerting using facial features and hand gestures. In: *2023 International Conference on Intelligent Computing and Control Systems (ICICCS)*. IEEE, 2023.
Disponível em: https://ieeexplore.ieee.org/document/10157233. Acesso em: 2025.

3. Uma Maheswari et al. (2022) — Multi-Aspect / FAR + EAR + MAR

UMA MAHESWARI, V.; ALUVALU, Rajanikanth; KANTIPUDI, M. V. V. Prasad; CHENNAM, Krishna Keerthi; KOTECHA, Ketan; SAINI, Jatinderkumar R.
Multi-aspect driver drowsiness prediction using image processing techniques. *IEEE Access*, v. 10, p. 61342–61355, 2022.
Disponível em: https://ieeexplore.ieee.org/document/9777952. Acesso em: 2025.

4. Ramya et al. (2024) — Driver Deficiency Detection (Haar Cascade)

RAMYA, M.; ANUVARSHINI, B. S.; KANIKA, G.; LOHITH, A.; BARATH, B.
Real-time driver deficiency detection system. In: *2024 International Conference on Smart Systems and Advanced Computing (ICSSAC)*. IEEE, 2024.
Disponível em: https://ieeexplore.ieee.org/document/11069879. Acesso em: 2025.

Referências

5. Zhu et al. (2022) — TCDCN + Eye/Mouth States

ZHU, Tianjun et al.
Research on a real-time driver fatigue detection algorithm based on facial video sequences. *Applied Sciences*, v. 12, n. 4, 2022.
Disponível em: https://www.mdpi.com/2076-3417/12/4/2224. Acesso em: 2025.

6. Essahraui et al. (2025) — Review / ML Techniques

ESSAHRAUI, Siham et al.
Real-time driver drowsiness detection using facial analysis and machine learning techniques. *Sensors*, v. 25, n. 3, 2025.
Disponível em: https://www.mdpi.com/1424-8220/25/3/812. Acesso em: 2025.

7. Albadawi et al. (2023) — ML-Based + IR Camera + Head Pose

ALBADAWI, Yaman; ALREDAHEI, Aneesa; TAKRURI, Maen.
Real-time machine learning-based driver drowsiness detection using visual features. *Journal of Imaging*, v. 9, n. 5, 2023.
Disponível em: https://www.mdpi.com/2313-433X/9/5/91. Acesso em: 2025.

8. Baul et al. (2023) — MediaPipe Face Mesh

BAUL, Saikat; RANA, Md. Ratan; TRISNA, Nusrat Jahan; ALAM, Farzana Bente.
Development of a real-time driver's drowsiness detection system using MediaPipe Face Mesh. *International Journal of Engineering and Manufacturing*, v. 15, n. 5, p. 41–51, 2023.
Disponível em: https://www.mecs-press.org/ijem/ijem-v15-n5/v15n5-4.html. Acesso em: 2025.

Referências

9. Florez et al. (2024) — CNN + MAR + IR Camera

FLOREZ, Ruben; PALOMINO-QUISPE, Facundo; ALVAREZ, Ana Beatriz; COAQUIRA-CASTILLO, Roger Jesus; HERRERA-LEVANO, Julio Cesar.
A real-time embedded system for driver drowsiness detection based on visual analysis of the eyes and mouth using convolutional neural network and mouth aspect ratio. *Sensors*, v. 24, n. 19, 2024.
Disponível em: https://www.mdpi.com/1424-8220/24/19/6261. Acesso em: 2025.

10. MediaPipe (Documentação oficial)

GOOGLE.
MediaPipe Documentation: Face Mesh, Hands, and Solutions. 2023.
Disponível em: https://developers.google.com/mediapipe. Acesso em: 2025.

11. EAR – Eye Aspect Ratio

SOUKUPOVÁ, Tereza; ČECH, Jan. *Real-Time Eye Blink Detection Using Facial Landmarks*. In: **Computer Vision Winter Workshop (CVWW)**, 21., 2016, Rimske Toplice. Proceedings [...]. Ljubljana: University of Ljubljana, 2016. Disponível em: https://vision.fe.uni-lj.si/cvww2016/proceedings/papers/05.pdf. Acesso em: **07 dez. 2025**.

12. PERCLOS – Percent Eye Closure

DINGES, David F.; GRACE, Richard. *PERCLOS: A Valid Psychophysiological Measure of Alertness as Assessed by Psychomotor Vigilance*. Washington, DC: Federal Highway Administration; Office of Motor Carriers, 1998. Disponível em: https://rosap.ntl.bts.gov/view/dot/4003. Acesso em: **07 dez. 2025**.

13. MAR – Mouth Aspect Ratio (bocejo)

HARIRI, Wissam; AL SAEEDI, Ahmed; EL RUBE, Iyad. *Driver Drowsiness Detection Using Mouth Aspect Ratio and Eye Aspect Ratio*. International Journal of Engineering and Advanced Technology (IJEAT), v. 8, n. 6, p. 1521–1527, 2019. Disponível em: https://www.ijeat.org/. Acesso em: **07 dez. 2025**.

OBRIGADA!